Agro 5.0: O avanço tecnológico com algoritmos de Machine Learning contribuem para a otimização das safras e sustentabilidade no campo .

Adauto Tadeu de Carvalho Junior [*] $and Alexandre da Silva Simões$ [§]

[*,§] São Paulo State University (UNESP)
Institute of Science and Technology of Sorocaba (ICTS)
Campus of Sorocaba, Brazil

[†,‡] São Paulo State University (UNESP)
Av. Profa. Isette Corrêa Fontão, 505
São João da Boa Vista, SP, Brazil

Email: [*] adauto.junior@unesp.br, [§] alexandre.simoes@unesp.br

Este trabalho desenvolvido para a conclusão da disciplina de Aprendizado de Máquina Supervisionado no Programa de Pós- Graduação de Engenharia Elétrica da UNESP-Sorocaba/SP, consiste em apresentar as tecnologias disponíveis no universo agro-rural nesse momento, com enfâse na utilização de algoritmos de Machine Learning e através deles realizar testes e classificações para a melhoria no que diz respeito a uma das técnicas milenares, adotadas pela humanidade, que é a prática de cultivo no solo, propondo o uso dessa tecnologia, para melhorar o aproveitamento da safra desde o plantio a colheita, iniciando a pesquisa com a análise de solo para a classificação de espécies vegetais a serem cultivadas, monitorando o seu desenvolvimento prevenindo doenças e pragas e finalizando com as possíveis soluções que resultaram na otimização do custo da safra, sabendo que os modelos foram avaliados com base em dados reais de propriedades rurais, demonstrando seu potencial para apoiar decisões no campo de modo com que seja possível aumentar a produtividade com menor impacto financeiro e o que é melhor sem tantas dúvidas e incertezas.

Palavras Chave: Agricultura 5.0,Agricultura de Precisão,Machine Learning, Análise de Solo, Classificação de Espécies, Otimização de Custos

I. Abstract

This work for the conclusion of the Supervised Machine Learning discipline in the Postgraduate Program, consists of presenting the technologies available in the agro-rural universe at that time, with emphasis on the use of Machine Learning algorithms and through them tests and classifications were carried out for improvement regarding one of the ancient techniques provided by humanity, which is the practice of cultivation in the soil, proposing the use of this technology, to improve the use of the crop from planting to harvest, starting the research from soil analysis to the classification of plant species to be cultivated, monitoring their development, preventing diseases and realities and ending with the possible solutions that resulted in the optimization of the cost of the crop, it is worth mentioning that the models were evaluated based on real data from rural properties, demonstrating their potential to support decisions in the field so that it is possible to increase productivity with less financial impact and what is best without so many doubts and uncertainties.

***Index Terms*—Agriculture 5.0, Precision Agriculture, Machine Learning, Soil Analysis, Species Classification, Cost Optimization.**

II. Introdução

Ao longo do tempo observou-se de maneira equívocada o campo e toda a zona rural como áreas tecnológicamente atrasadas, e ou, portadoras de técnicas arcaicas e obsoletas.

Atualmente, a chamada Agricultura 5.0, contradiz esse cenário ao incorporar uma série de tecnologias e aplicações que promovem maior eficiência e sustentabilidade ao setor agrícola em geral.

A agricultura de precisão tem ganhado destaque no cenário brasileiro, portanto a presente proposta é investigar e apresen-

tar como algoritmos de aprendizado de máquina podem contribuír para decisões mais assertivas em relação ao plantio, não somente utilizando dados de solo, clima e produtividade,temos como objetivo claros alguns pontos muito importantes e que devem ser elencados :

(i) classificar espécies de cultivo mais viáveis;

(ii) prever produtividade conforme as características do solo;

(iii) minimizar custos com insumos e manejo.

(iiii)analisando safras anteriores otimizar resultados futuros.

Sabendo que o Brasil é o país que mais contribui para a produção agrícola no mundo, e se encontra na linha de frente de implantação de inovações tecnológicas na agricultura juntamente com Austrália, Bélgica, Reino Unido, Estados Unidos e Japão, o país lidera a produção de grãos para exportação. Mesmo já possuíndo muitas literaturas abordando o presente tema, é correto voltarmos os olhos para esse setor de extrema importância no momento em que o planeta está com a atenção voltada para o tema da referida pesquisa. Utilizando dados públicos e reais, propõe-se a partir desse estudo um sistema preditivo que incorpora algoritmos de Machine Learning para otimizar o processo produtivo, identificar gargalos e explorar possibilidades de inovação no que se refere ao tema proposto. Apesar de termos avançado de forma exponencial nesse segmento, uma grande preocupação ainda é a integração das diversas técnicas e equipamentos que estão sendo inseridos no campo de maneira desenfreada, em um único sistema que possibilite ao produtor rural, uma maior facilidade de observar e tomar decisões sem a necessidade de um agrônomo in loco como via de regra.

Outra demanda que surge com o avanço da tecnologia no campo é relativo a competitividade que os pequenos produtores são obrigados a enfrentar, quase sempre como uma batalha desigual, com aqueles que dispõe-se de recursos para a implementação de tecnologias de ponta muito antes do agricultor familiar.

Sabe-se também que em algumas regiões o cultivo é muito precário e também carente de ferramentas que possibilitem cultivar, sem ter que conviver com as incertezas da safra e por depender totalmente de condições desconhecidas.

Com o avanço da I.A. e a disponibilidade de algoritmos de Machine Learning unidos ao surgimento de maquinários automatizados, robôs , sensores e o advento da Internet das Coisas no agronegócio. O nosso país tende a ganhar ainda mais destaque nesse segmento desde que saibamos aproveitar totalmente os recursos que a natureza nos oferece.

A internet também tornou-se imprescindível para tais práticas, porém, devido ao avanço das energias sustentáveis e também do fornecimento de links pelas operadoras e provedores, o campo tem se mostrado muito presente e conectado as novas tecnologias, por esse motivo se tornou coerente e viável a abordagem dessa pesquisa, isso sem contar que as indústrias fabricantes de máquinas para esse segmento ampliaram exponencialmente a infraestrutura dos implementos com tecnologias de última geração.

Vale ressaltar que no ano de 2024, a pesquisadora brasileira Mariangela Hungria foi premiada como a primeira mulher brasileira a receber uma premiação internacional nesse segmento, a engenheira agronoma da EMBRAPA foi a vencedora do Prêmio Mundial da Agricultura(World Food Prize) considerado o Nobel da Agricultura. [11]

III. Materiais e Métodos

A aplicação da pesquisa na fase inicial, tem por base a exploração das condições do solo por meio de variáveis como pH, N(Nitrogênio), P(Fósforo) K(Potássio), umidade e temperatura como vemos na imagem a seguir Fig.1.

Poderá existir um aplicativo para qualquer situação onde uma pessoa poderá visualmente tirar a sua conclusão. Mas não só de imagens, como de dados meteorológicos e de solo [10]

O cultivo de qualquer cultura na maioria das vezes depende das condições climáticas de sua região. Portanto, a análise das condições agroclimáticas de uma determinada localidade tende a contribuír explícitamente com a prática de cultivo de espécies próprias da mesma. [1].

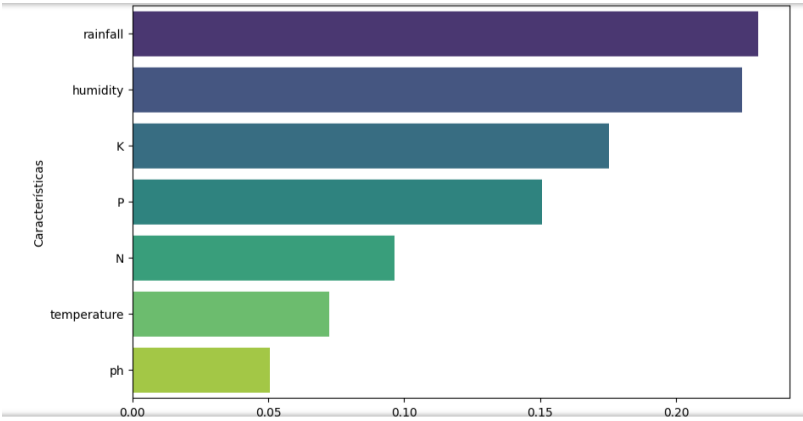


Figure 1. RECURSOS OBSERVADOS

Essas variáveis foram de extrema importância para a escolha da espécie a ser cultivada, destacando a variável rainfall(chuva), óbviamente com a maior percentualidade de importância pois foram utilizadas para treinar classificadores com maior precisão.

Também para isso, sabendo-se do seu desempenho favorável, através de estudos realizados anteriormente, utilizou-se o algoritmo conhecido como Random Forest. Implementado no ambiente de execução Google Colab e a linguagem Python com suas bibliotecas, mas também optou-se por implementar outros algoritmos de machine learning como o: KNN(K-Nearest Neighbors), o SVM (Suport Vector Machine) e também Tree Decision, para comparar as validações através de matrizes de confusão.

Ressaltando que a literatura recente tem explorado diversos modelos para previsão de culturas ideais, dentre eles, um estudo aprofundado como o apresentado por pesquisadores indianos [1] demonstraram que algoritmos como Random Forest alcançam acurácias superiores a 95% na recomendação de culturas baseadas em dados agroclimáticos.

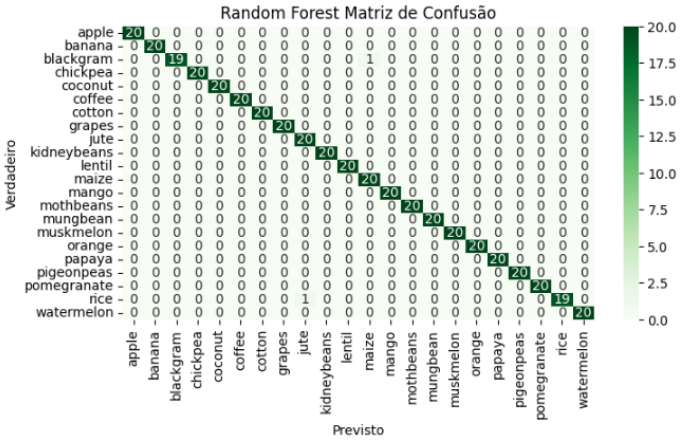


Figure 2. Matriz de Confusão(RANDOM FOREST)

Assim sendo, é correto destacar sempre a necessidade de se utilizar um algoritmo de aprendizado ativo para análises mais acuradas que necessitam de uma maior precisão. Também é correto afirmar que o Random Forest esclareceu sobremaneira quais opções se apresentaram mais viáveis para a escolha de cultivo, até por que o KNN não faz uma classificação, esse algoritmo por característica própria, somente calcula a distância do nosso K-vizinho e isso é insuficiente para a tarefa e os resultados esperados nessa fase do processo. "Na agricultura, existem diferenças climáticas e de iluminação. São diferentes fatores que quando você coleta esses dados, reproduzem variabilidade no problema [10]"

Apesar de possuírmos essas literaturas apontando para números altos de probabilidade que o Random Forest supre a necessidade nessa fase de seleção de cultura de cultivo, a fim de garantirmos a integridade dessa pesquisa e sua confiabilidade, foram realizadas comparações utilizando o dataset"CROP-RECOMMENDATION" [14] com outros algoritmos, dentre eles: Decision Tree e SVM. Também foram realizados alguns testes mais precisos tais como: a validação cruzada, nesse caso utilizou-se a cross-validation LOOCV(Leave-One-Out Cross-Validation)esse modelo trata-se de validar todo grupo, porém sempre deixando um dos conjuntos de dados como validação enquanto os demais compõem o teste e a cada rodada esse conjunto de validação é alternado [15].Tudo isso para que a primeira fase dessa pesquisa trouxesse comprovadamente a melhor opção de cultivo.

```
Random Forest (Acurácia média com CV=5): 0.9945454545454545
Decision Tree (Acurácia média com CV=5): 0.9868181818181819
KNN (Acurácia média com CV=5): 0.9795454545454545
SVM (Acurácia média com CV=5): 0.9781818181818182
```

Figure 3. CROSS-VALIDATION

Outra técnica utilizada nessa fase também para garantír confiabilidade foi ANOVA(oneway), a análise de variância unidirecional consiste em comparar dois ou mais grupos através de suas médias independentes para garantír que são diferentes através de evidências estatísticas, ou seja, no nosso caso que se trata de um estudo de campo, diferenças estatísticas de médias de dois ou mais grupos.

Onde comprovou-se a diferença das acurácias conforme apresenta o resultado a seguír, demostrado entre as médias das classes, utilizando o erro quadrático médio(MSE),possibilitando representar a variação estimada dentro de cada grupo após a contabilização das diferenças entre os grupos validando assim a evidência contra a hipótese nula, com a obtenção de um valor p geralmente menor ou igual a 0,05, isso indica que há diferença relevante e significativa entre as médias de pelo menos dois grupos .

```
Estatística F: 22.448979591836856
p-variavel: 5.6070411885740975e-06
```

Figure 4. Resultado da Variância Unidimensional(ANOVA(ONEWAY)

Uma vez que já obteve-se o cultivo adequado,com maior probabilidade de sucesso para a nossa próxima safra através de comparações dos algoritmos de machine learning utilizados.

Agora também é possível simular através de datasets como o PlantVillage [16] a prevenção de doenças relacionadas a cultura aplicada, criando uma Rede Neural Convolucional(CNN) que permite o monitoramento das plantas através das imagens coletadas e observando toda e qualquer variação no comportamento da espécie elencada.

Vale ressaltar que para essa fase foi necessário tratar de forma antecipada as imagens, dividindo-as em categorias como: treino, validação e teste e também preocupou-se em realizar uma auditoria, pesquisa minunciosa para garantír que o dataset em questão não possuísse nenhuma imagem inválida contendo extensões equívocadas, e ou, imagens corrompidas. Já que estamos falando de um dataset com um número bastante expressivo de dados e que pode acontecer de contêr algum tipo de ruído.

Outra técnica utilizada para essa fase, também de muita valia destacar para o trabalho realizado, foi a implementação da função ImageDataGenerator que pertence a biblioteca keras do tensorflow e que oferece a possibilidade de movimentação horizontal e vertical, além de girar espelhando ou não a referida imagem, garantindo detalhes específicos e enriquecendo ainda mais a análise do nosso alvo.

Contudo a rede utilizada para essa fase fez toda a diferença pois a Convolutional Neural Network trata-se específicamente de uma rede neural profunda bastante utilizada para o tratamento de imagens já que essa tarefa normalmente trabalha com um número bastante elevado de dados, inclusive nesse caso onde utilizou-se um dataset muito robusto como é o PlantVillage [16].

Portanto, essa rede é bastante apropriada pois tem por característica o reconhecimento de padrões através de classificações de imagens.

A sua arquitetura favorável deve-se ao fato da criação de camadas (LAYERS) e aplicações de filtros a cada camada, trabalhando com remoções de características irrele-

vantes(RELU) a cada convolução, reduzindo o tamanho do mapa de pesquisa(POOLING) até encontrar um vetor com características densas mais próximas daquilo que necessitamos observar.

Ou seja, de forma resumida a nossa rede ao repetír esse processo pode obter como saída tanto padrões visuais , como camadas mais profundas impossíveis de perceber a olho nú. Por exemplo, o exame das folhas pode revelar formas deformadas e descoloração nos tecidos infectados. Esses tecidos frequentemente apresentam manchas pretas, amarelas, pulverulentas ou de crestamento [2].

Mas também pode-se constatar através de uma técnica chamada softmax, algumas probabilidades que norteiam entre a saúde plena e o risco de doenças e pragas na cultura observada. Já existe há algum tempo a preocupação mundial com a perca de alimentos e os cuidados necessários para amenizar esse problema.

A Organização das Nações Unidas para a Alimentação e a Agricultura (FAO) estima que US$ 220 bilhões são perdidos em todo o mundo devido a doenças nas plantações, que representam mais de 20% das colheitas produzidas anualmente [12]

Prever a produção de uma safra é uma das tarefas mais desafiadoras e complexas mesmo com a chamda agricultura de precisão, onde se utiliza de sensores, imagens e diversos componentes digitais que auxiliam e parametrizam argumentos para o mapeamento da produtividade, planejamento do mercado agrícola, o seguro agrícola e a gestão da colheita. [17]

Além disso, abordagens que integram imagens multiespectrais de satélite, como o uso dos dados Sentinel-2 para análise de NDVI(Índice de Vegetação por Diferença Normalizada), têm contribuído significativamente para a identificação de áreas mais produtivas e monitoramento do estresse hídrico [9].

Portanto, a combinação entre dados tabulares, imagens e sensores IoT, com o suporte de algoritmos de ML, tem se mostrado promissora para o avanço da agricultura de precisão.Nesse estudo também considerou-se gráficamente apresentar algumas correlações entre as principais variáveis e suas condições. Por exemplo o gráfico a seguír ilustra que a retenção de água e o índice foliar possuem uma correlação muito ponderante uma vez que a planta se bem irrigada possuirá provávelmente uma folhagem mais expessa e saudável.

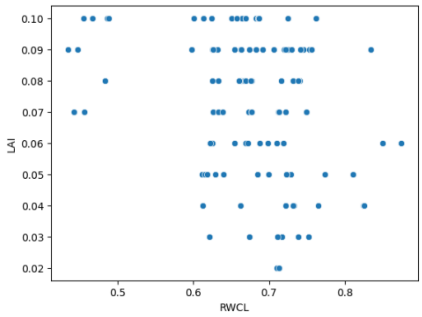


Figure 5. RWCL X LAI

No próximo exemplo pode-se afirmar que se trata de uma das demonstrações mais relevantes desse trabalho pois expõe a análise visual que permite avaliar como diferentes níveis de retenção de água(RWCL) interferem na produtividade da soja(SYUA).

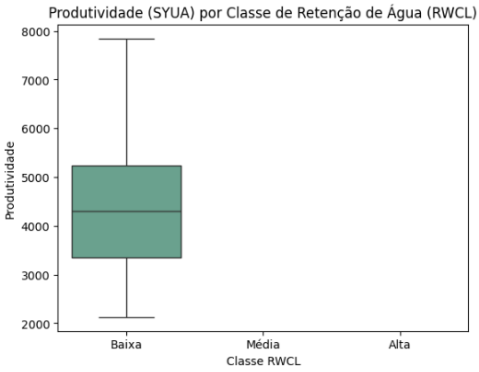


Figure 6. SYUA X RWCL

Diante disso podemos afirmar que nos últimos anos sistemas com base em Machine Learning, como robôs de controle de plantas daninhas (LaserWeeder G2) e também plataformas de IOT utilizadas para monitoramento e controle de solo demonstraram impacto direto contribuindo para a redução de insumos e aumento da sustentabilidade. [8]

E por esse motivo a implementação de tecnologias e técnicas utilizando inteligência artificial e aprendizado de máquina tem contribuído cada vez mais para o avanço do desenvolvimento do agronegócio.

Tendo esclarecido algumas dúvidas pertinentes ao tema abordado nessa pesquisa, pleiteou-se investigar como monitorar o peso biológico e sua correlação com o desenvolvimento saudável da planta,o gráfico a seguír traz essa exposição de forma bastante ilustrativa e de fácil compreensão.

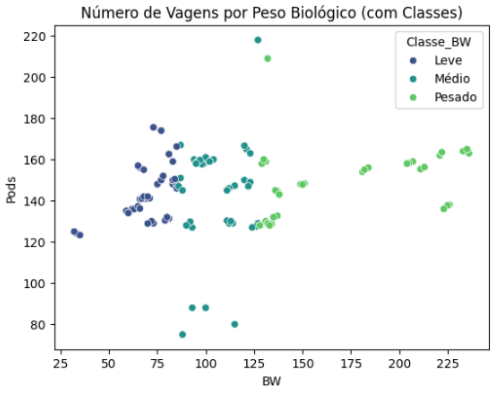


Figure 7. PODS X BW

Essa ilustração indica claramente que nas áreas onde se concentram as plantas com BW mais pesados também se encontram as espécies com maior número de vagens, indicando uma relação positiva entre o acumulo de biomassa e a produtividade reprodutiva da planta.

Agora já partindo para a finalização dessa pesquisa de uma forma coerente e promissora, vamos também abordar uma breve demonstração de como prever resultados de acordo com dados das safras passadas.Para isso optou-se por utilizar RNN(Redes Neurais Recorrentes), mais precisamente um algoritmo de modelo LSTM e o dataset Agriculture Crop Yield. [18] Com isso, podemos observar através de três safras anteriores quais serão as perspectivas para a próxima colheita e consequentemente, customizar a produção da próxima safra.

Para isso foi implementada uma série temporal com base nas colheitas por hectare das safras anteriores e assim pudemos constatar a previsão para a nossa próxima safra com maior precisão.

IV. ABORDAGEM PROPOSTA

Todas as demonstrações e comparativos apresentados nesse trabalho acadêmico foram relacionados aos tópicos e temas apresentados durante as aulas da disciplina Supervised Machine Learning, sendo assim afirma-se que os cálculos e fórmulas aplicados são equivalentes aos desenvolvidos ao longo do curso a começar pelas função de perda e acurácia durante o treinamento. A função de perda descreve-se como uma forma mensurável de avaliar o desempenho e a precisão do modelo de aprendizado de máquina dentre eles os dois que mais utilizamos foram MSE(Erro Quadrático Médio-L2) e o MAE(Erro Absoluto Médio-L1) [20].

Outro exemplo bastante utilizado foi a função sigmoid que:

Em sua essência, a função sigmoide é uma equação matemática que mapeia qualquer número de valor real para um valor entre 0 e 1, o que a torna ideal para saídas probabilísticas. Sua fórmula é dada abaixo:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Figure 8. Fórmula da Função Sigmoid

Resumidamente essa função é amplamente utilizada na ciência de dados tanto como classificação binária, como função de ativação.

Segundo literaturas publicadas [13] anteriormente descreve-se essas técnicas da seguinte maneira:

Classificação Binária: Pode ser utilizada para previsões dos mais diversos segmentos utilizando a transformação da saída de um modelo em uma pontuação de probabilidade específica.

Função de Ativação: Nesse caso a referida função acrescenta a não linearidade o que contribui para que o modelo aprenda padrões complexos sobre os dados apresentados.

Outra técnica utilizada que foi bastante mencionada e explorada durante as aulas foi o algoritmo de retropropagação, onde o mesmo consiste em alterar os parâmetros dos neurônios individuais de forma que a previsão do modelo e o valor real coincidam o mais rápido possível. [19]

V. RESULTADOS E DISCUSSÃO

Comparando a avaliação dos algoritmos, para a escolha da espécie de cultivo, temos como melhor desempenho geral o Random Forest com uma acurácia de : 99,45% o que confirma sua robustez e capacidade de lidar bem com dados variados e sujeitos a ruídos, também pode-se afirmar que devido a sua natureza essemble(várias árvores)tem como característica a redução de riscos de overfitting. Já a Decision Tree(Árvore de Decisão) também obteve um bom desempenho para essa tarefa 98,68% o que não causou surpresa tendo em vista que o Random é uma técnica que inclui diversas árvores melhorando assim a generalização de maneira considerável. Enquanto que o KNN e o SVM apresentaram desempenhos muito parecidos entre 97,8 % e 97,9% o que não é tão ruím, porém, que não estão ao mesmo nível dos algoritmos de árvores que performaram muito melhor para esse dataset [14], nessa respectiva fase do processo.

```
Random Forest (Acurácia média com CV=5): 0.9945454545454545
Decision Tree (Acurácia média com CV=5): 0.9868181818181819
KNN (Acurácia média com CV=5): 0.9795454545454545
SVM (Acurácia média com CV=5): 0.9781818181818182
```

Figure 9. Cross Validation: compara as acurácias dos modelos

Comprovadamente através da validação cruzada entre os modelos treinados para consolidar a validação de treinamento e testes desses algoritmos. Com base na validação cruzada utilizando séries temporais (cv=5), o Random Forest realmente apresentou a melhor acurácia média com 99,45% , o Decision Tree seguiu de perto com 98,68% , já o KNN com 97,95% e o SVM com 97,82% apenas reforçam a tese de que o Random Forest é o algoritmo mais apropriado para a fase de recomendação de cultura para cultivo com as variáveis utilizadas devido ao seu desempenho e robustez, mesmo levando em consideração uma pequena margem de diferença entre eles, o Random Forest proporciona um maior grau de confiabilidade nessa fase do projeto enquanto que os demais podem servir de apoio para análise de sensibilidade e até aproveitados em outras fases posteriormente caso se faça necessário. Ou seja, esse resultado apontou através da estatística que a variabilidade entre os modelos é maior que a variabilidade dentro dos grupos que foram analisados na validação cruzada.Também pode-se comprovar que o valor de: p-variável= $p < 0.00001$

Conclui-se no entanto que o Random Forest com a maior acurácia média é estatísticamente superior e no entanto o modelo mais apropriado para essa fase de seleção de cultura para o cultivo.

A Decision Tree por sua vez foi de extrema eficácia para o monitoramento do desenvolvimento do plantio, também em todos os casos foi adotada a técnica de **Early Stop**, que possibilita identificar o melhor modelo do algoritmo na fase de treino quando ao convergír ele não evolui no aprendizado e salvá-lo, popularmente conhecido como **best Keras.** Já

no que se refere ao monitoramento através de imagens a CNN (Network Neural Convolutional) apresentou de forma assertiva características capazes de identificar indicadores de saúde e também de prováveis infecções, portanto, comprovou com isso eficiência nessa tarefa de prevenção de pragas e doenças. Tamanha é a importância desse algoritmo no ramo da agricultura de precisão, que incentivou o empresário e CEO da **Carbon Robotic** Paul Mikesell a abandonar um projeto mega inovador de carros autonomos na Uber e com a experiência adquirida migrar para a fabricação de robôs para prevenção de ervas daninhas, com isso Mikesell incentivou gigantes do ramo agroindustrial a desenvolver máquinas agrícolas capazes de utilizar as CNNs em diversas tarefas que necessitam de detecção de imagens com ou sem conexão com a internet como é o caso da LaserWeeder que possui um banco de dados com imagens de ervas daninhas e utiliza o hardware do computador na própria máquina para operar, esse avanço representa o início de uma nova era na agronomia mundial. [8]

Finalmente foi obtêr estimativas através de previsões baseadas em safras passadas devido a utilização do modelo RNN-LSTM com base no conjunto de dados públicos [18]que foi criado justamente com o objetivo de realizar previsões de produtividade por cultura(em toneladas por hectare) e sempre analisando diversos fatores.Suas principais variáveis são: a região, o tipo de solo, a cultura, a precipitação em milímetro, a temperatura em graus celsius, a aplicação de fertilizantes,a irrigação e também a condição climática.

Esses são os fatores que permitem uma previsão sólida e de alta taxa de probabilidade para previsão de futuros resultados, vale lembrar que aqui nessa fase estamos trabalhando com algoritmos já com um nível alto de complexidade e também com muita demanda de processamento do hardware portanto é natural que o mesmo leve um tempo expressivo para convergír, além do que o dataset [18] possui um grande número de amostras a serem consultadas.

Como já mencionado, foi realizada uma breve demonstração utilizando o modelo LSTM e constatado que a rede convergiu mais rapidamente a partir da 5 época até a 15 porém desse ponto em diante a perda na curva de erro medida pelo MSE se mostrou quase que imperceptível devido a variedade e a organização dos dados.

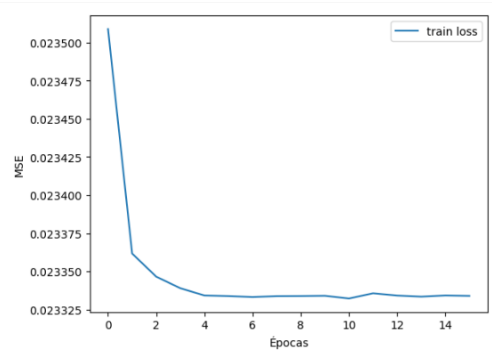


Figure 10. Train-Loss - LSTM

VI. Conclusão

Dentro de um cenário repleto de variáveis e variações optou-se por investír em técnicas e algoritmos que possibilitem a maior clareza possível com relação aos resultados esperados dentro de um contexto probatório. A utilização de conjunto de dados públicos proporcionou uma maior visibilidade no que foi proposto desde o início desse trabalho científico, correspondendo todas as fases do desenvolvimento e também colaborando para uma maior amplitude nas demonstrações apresentadas. Acreditando que dentro do escopo inicial foram utilizadas fórmulas e técnicas apresentadas em aula, contudo sabendo que por tratar-se de um trabalho acadêmico, muito pode ser melhorado e aprofundado, tendo em vista que a ciência tem como característica principal o avanço em todas as áreas.

Nesse caso com a expansão industrial e com novas tecnologias surgindo muito rápidamente, dentro de pouco tempo essas abordagens de ML já estarão ultrapassadas, porém a sua base consistirá na minha opinião.

Uma vez que sem o alto número de dados armazenados nada se pode mensurar, concluíndo assim que novas pesquisas devem e serão realizadas inovando a forma com que se apresentarão as tendências no agronegócio. Mas é extremamente recomendável manter os dados sempre seguros e com menos ruídos possíveis para análises futuras.

Agradecimentos

Primeiramente, sou grato a Deus pela oportunidade concedida e a minha esposa **Luciane Carpes de Carvalho** pela paciência e respeito de sempre para com os meus estudos, tendo em vista que nesse período muitas das nossas atividades cotidianas precisaram ser alteradas. Também sou grato aqueles que me apoiaram e me incentivaram a enfrentar esse novo desafio,a minha saudosa mãe que não teve oportunidade de ver esse trabalho concluído e toda a minha família.

Ao meu amigo irmão Eng. Agrônomo: **Diego Leal** pelas dicas e todos os esclarecimentos com relação ao uso de insumos e também sobre a automação na lavoura, minha cunhada **Eliana Carpes** pela torcida e também pela colaboração na revisão desse artigo, professores: **Adriano Daniel Elias e André Mello de Almeida Junior**, meus companheiros que sempre acreditaram que sería capaz concluír com exito essa disciplina. Todos os meus colegas de turma, pelo companheirismo de sempre, foi muito bom estar com todos nessa jornada.

Aqui deixo também minha eterna gratidão e respeito ao docente dessa disciplina, **prof.Alexandre da Silva Simões** que além de expert e perito nessa área também contribuiu efetivamente para que todos nós nos interessassemos ainda mais por esse universo da inteligência artificial, aprendizado de máquina e todas as tecnologias emergentes. Meu muito obrigado pela oportunidade de aprender tanto sobre um assunto tão inovador de uma forma muito sucinta e que enriqueceu muito o nosso conhecimento.

REFERENCES

[1] Rani, S., Mishra, AK, Kataria, A. et al. , *Machine learning-based optimal crop selection system in smart agriculture*, Creative Commons, 2023. https://doi.org/10.1038/s41598-023-42356-y

[2] Angelo Randaci, Earth's Ally. (2021, March 10).

[3] Business Insider, "AI tools could transform how farmers tackle weed control," Business Insider, Jun. 26, 2025. [Online]. Available: https://www.businessinsider.com/ai-tools-weed-control-efficiency-farming-agriculture-2025-6

[4] Z. Xu, A. Karthik, K. Guo, J. Liu, and M. Gong, "iNatAg: Multi-Class Crop Classification Models Enabled by a Large-Scale Benchmark Dataset", arXiv preprint arXiv:2503.20068, 2024. [Online]. Available: https://arxiv.org/abs/2503.20068

[5] "IA e agronegócio no Brasil – Conheça o Agro 5.0 e as empresas que estão investindo no setor," Data Center Dynamics, 2024. [Online]. Available: https://www.datacenterdynamics.com/br/análises/ia-e-agronegocio-no-brasil-conheca-o-agro-50-e-as-empresas-que-estao-investindo-no-setor/. [Accessed: Jun. 29, 2025].

[6] M. Hungria, "Primeira brasileira a receber o 'Nobel' da Agricultura: Prêmio Mundial da Alimentação," Embrapa Soja, 2024. [Online]. Available: https://www.worldfoodprize.org/en/laureates/2025_hungria/.

[7] Food and Agriculture Organization of the United Nations. (2019). *FAO – News article: New standards to curb the global spread of plant pests and diseases*. [Online] https://www.fao.org/news/story/en/item/1187738/icode/*Common plant diseases & disease control for organic gardens https://earthsally.com/disease-control/common-plant-diseases.html*

[8] Business Insider, "AI tools could transform how farmers tackle weed control," Business Insider, Jun. 26, 2025. [Online]. Available: https://www.businessinsider.com/ai-tools-weed-control-efficiency-farming-agriculture-2025-6

[9] Z. Xu, A. Karthik, K. Guo, J. Liu, and M. Gong, "iNatAg: Multi-Class Crop Classification Models Enabled by a Large-Scale Benchmark Dataset", arXiv preprint arXiv:2503.20068, 2024. [Online]. Available: https://arxiv.org/abs/2503.20068

[10] "IA e agronegócio no Brasil – Conheça o Agro 5.0 e as empresas que estão investindo no setor," Data Center Dynamics, 2024. [Online]. Available: https://www.datacenterdynamics.com/br/análises/ia-e-agronegocio-no-brasil-conheca-o-agro-50-e-as-empresas-que-estao-investindo-no-setor/. [Accessed: Jun. 29, 2025].

[11] M. Hungria, "Primeira brasileira a receber o 'Nobel' da Agricultura: Prêmio Mundial da Alimentação," Embrapa Soja, 2024. [Online]. Available: https://www.worldfoodprize.org/en/laureates/2025_hungria/.

[12] Food and Agriculture Organization of the United Nations. (2019). FAO – News article: New standards to curb the global spread of plant pests and diseases. [Online] https://www.fao.org/news/story/en/item/1187738/icode/

[13] https://www.datacamp.com/pt/tutorial/sigmoid-function: :text=sobre

[14] A. Ingle, "Crop Recommendation Dataset," Kaggle, 2022. [Online]. Available:https://www.kaggle.com/datasets/atharvaingle/crop-recommendation-dataset.https://jornal.usp.br/universidade/pesquisadora-formada-na-usp-recebe-o-premio-world-food-prize-considerado-o-nobel-da-agricultura/

[15] LOOCV (Leave One Out Cross-Validation) na programação R,geeksforgeeks.org,2025[Online] https://www.geeksforgeeks.org/loocvleave-one-out-cross-validation-in-r-programming/ 2

[16] D. P. Hughes and M. Salathé, "An open access repository of images on plant health to enable the development of mobile disease diagnostics," arXiv preprint arXiv:1511.08060, 2015. [Online]. Available: https://arxiv.org/abs/1511.08060D. P. Hughes and M. Salathé, "An open access repository of images on plant health to enable the development of mobile disease diagnostics," arXiv preprint arXiv:1511.08060, 2015. [Online]. Available: https://arxiv.org/abs/1511.08060

[17] K. G. Liakos, P. Busato, D. Moshou, S. Pearson, and D. Bochtis, "Machine learning in agriculture: A review," Sensors, vol. 18, no. 8, p. 2674, 2018. [Online]. Available: https://doi.org/10.3390/s18082674. [Accessed: Jun. 29, 2025].

[18] S.O.Attakorah, "Agriculture Crop Yield," Kaggle, Set.2024. [Dataset]. Disponível em: https://www.kaggle.com/datasets/samuelotiattakorah/agriculture-crop-yield. Acesso em: 28-Jun-2025.

[19] "Compreendendo o algoritmo de retropropagação"-4 de dezembro de 2021. Aprendizado de máquina. Disponível em:https://databasecamp.de/en/ml/backpropagation-basics. Acesso em: 02-Jul-2025.

[20] "Explicação das funções de perda no aprendizado de máquina"-24 de Abril de 2024 Explore o papel crucial das funções de perda no aprendizado de máquina com nosso guia abrangente. Entenda a diferença entre as funções de perda e de custo, aprofunde-se em vários tipos, como MSE e MAE, e aprenda suas aplicações em tarefas de ML. Disponível em:https://www.datacamp.com/pt/tutorial/loss-function-in-machine-learning. Acesso em: 02-Jul-2025.