TRABALHO FINAL

DISCIPLINA: SUPERVISED MACHINE LEARNING

PROGRAMA: PPGEE(PROGRAMA DE PÓS-GRADUAÇÃO DE ENGENHARIA ELÉTRICA)

INSTITUTO DE PESQUISA CIENTÍFICA DA UNESP-SOROCABA

Aluno: Adauto Tadeu de Carvalho Junior

Docente: Prof. Dr. Alexandre da Silva Simões

AGRO 5.0:

“O AVANÇO TECNOLÓGICO COM ALGORITMOS DE ***MACHINE LEARNING*** CONTRIBUEM PARA A OTIMIZAÇÃO DAS SAFRAS E SUSTENTABILIDADE NO CAMPO”.

ESTRUTURA DO TRABALHO ACADÊMICO

1) classificar espécies de cultivo mais viáveis;

Fase 1: Desenvolvimento da pesquisa e implementação de algoritmos de Machine Learning para classificação de espécies para o cultivo com base em dados do Dataset Crop Recommendation, validação cruzada, variância unidimensional.

2) prever produtividade conforme as características do plantio;

Fase 2: Elaborado estudos utilizando imagens para classificação desde os contornos e bordas até camadas mais densas, utilização do Dataset PlantVillage e implementação de CNN.

3) minimizar custos com insumos e manejo;

Fase 3: Implementação do modelo Tree Decision para monitoramento não só do crescimento mas do desenvolvimento em geral da planta considerando variáveis como peso biológico, número de vagens, iluminação, retenção de água entre outros, IOT Dataset.

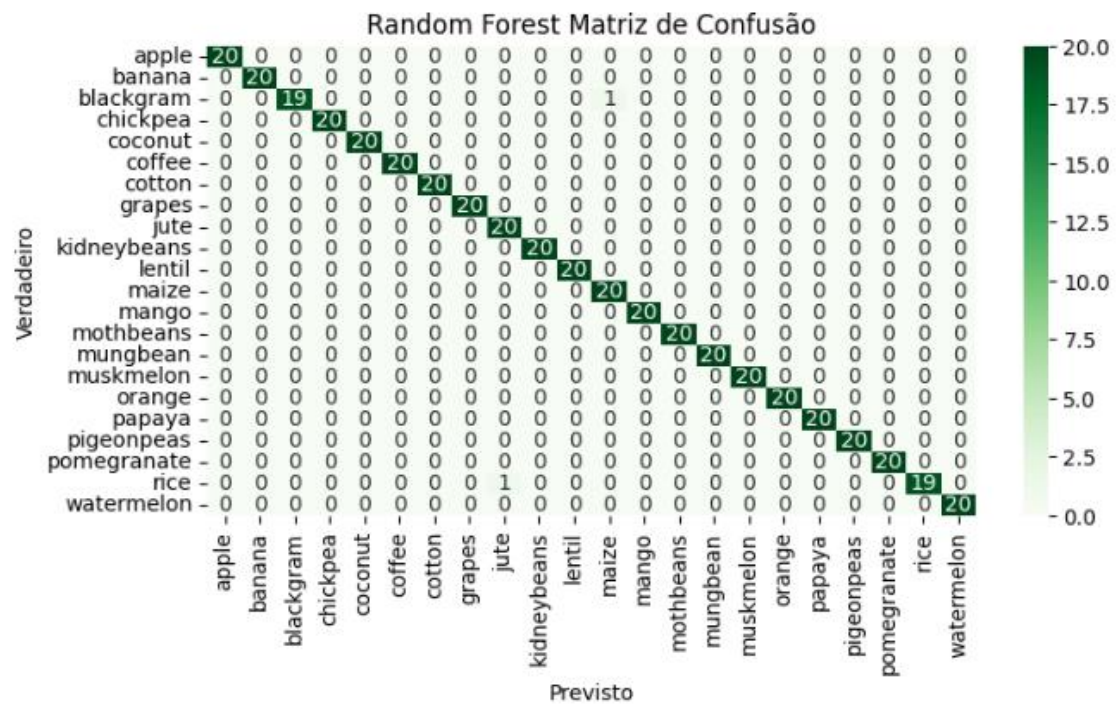
4)analisando safras anteriores otimizar resultados futuros.

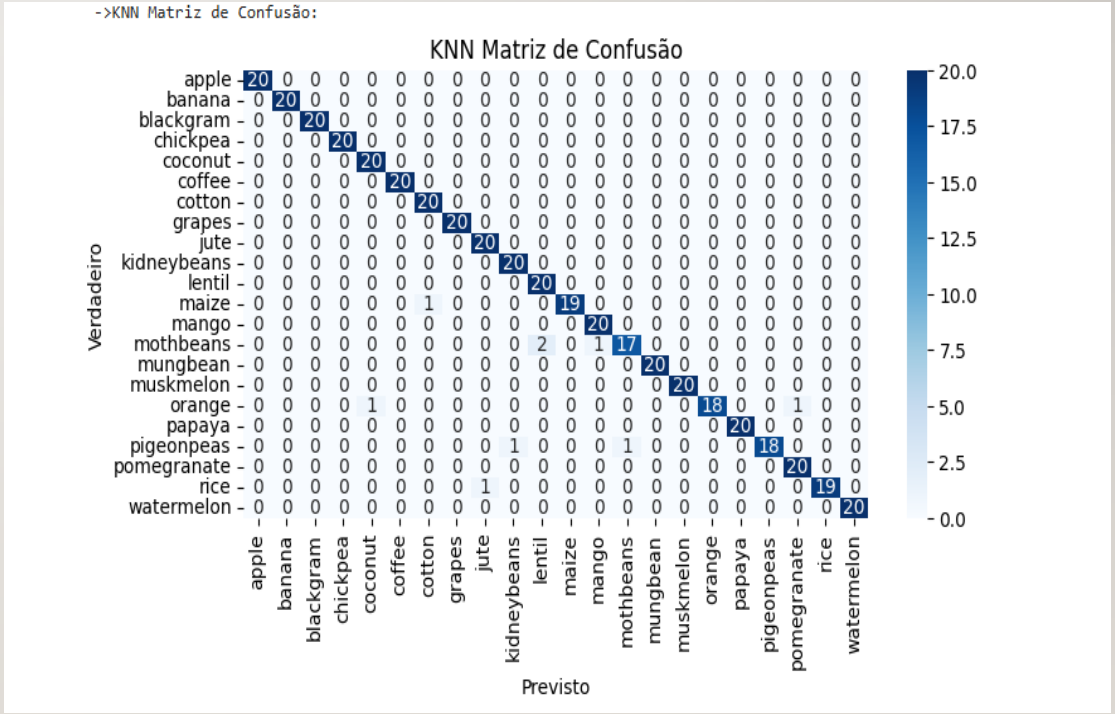
Fase 4: Na nossa fase final foi implementada uma RNN(LSTM) para analisar diante dos dados obtidos em 3 safras anteriores informações capazes de nortear safras futuras e comprovando assim os benefícios que o Machine Learning podem proporcionar no agronegócio, Crop Yield.

FASE INICIAL: ALGORITMOS MACHINE LEARNING

- Fase 1: Desenvolvimento da pesquisa e implementação de algoritmos de Machine Learning para classificação de espécies para o cultivo com base em dados do Dataset Crop Recommendation, foram utilizados os seguintes modelos:
- Forest Random: consiste na criação de um conjunto de árvores de forma aleatória;
- KNN: algoritmo de classificação ou regressão baseado em instâncias.
- Decision Tree: cria uma árvore onde cada nó representa uma decisão baseada em uma feature(recurso)fazendo a divisão dos dados até alcançar a previsão nos últimos nós.
- SVM: ideal para encontrar o hiperplano ótimo que separa as classes com maior margem possível entre os vetores de suporte, geralmente utilizado com pequenas quantidades de dados para treinamento.

FASE INICIAL: COMPARANDO OS MODELOS





FASE INICIAL: COMPARANDO OS MODELOS

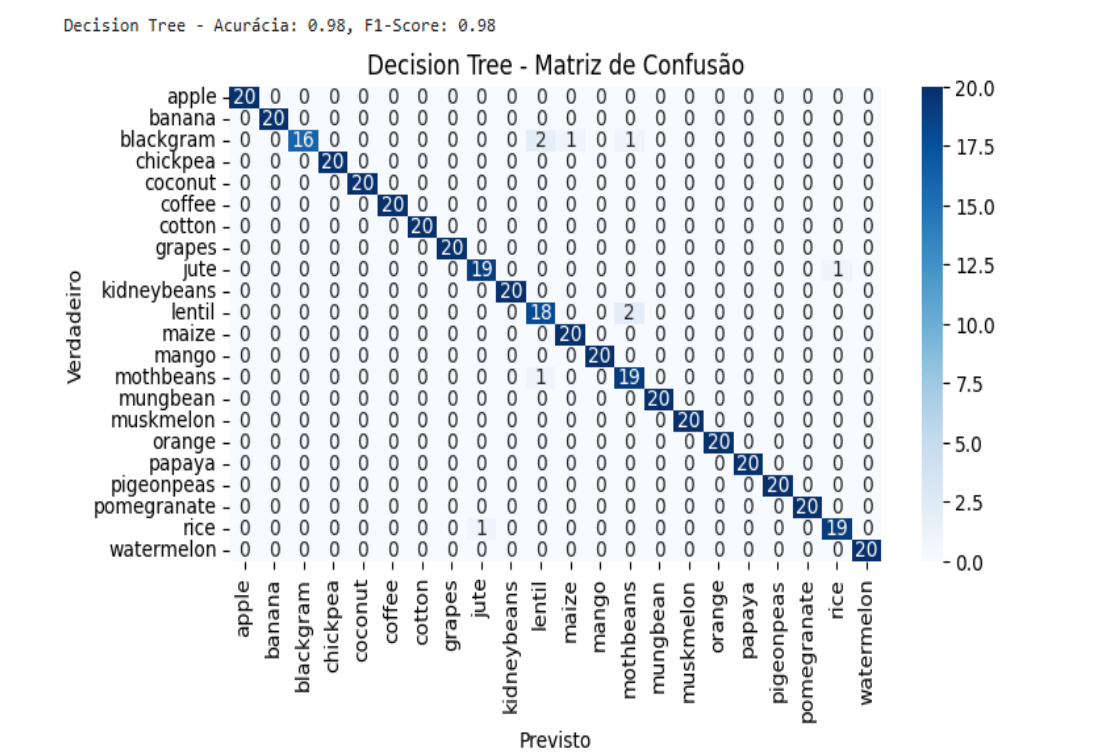
->Random Forest Relatório de Classificação:

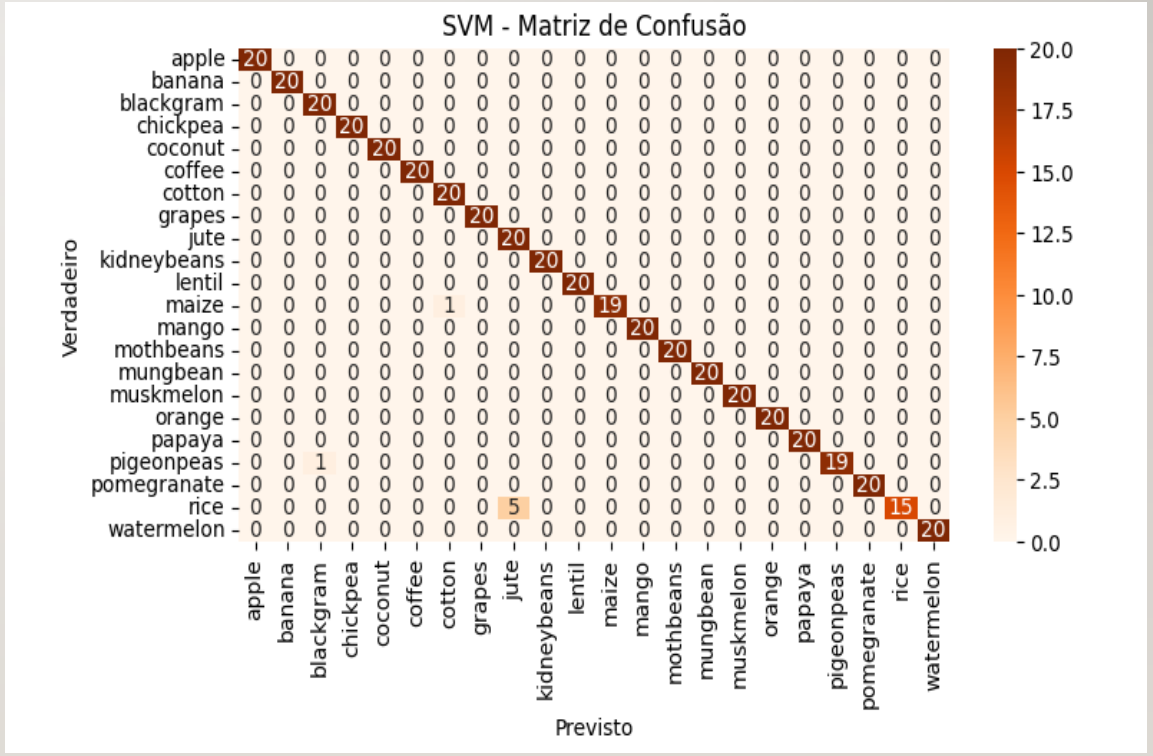
	precision	recall	f1-score	support
apple	1.00	1.00	1.00	20
banana	1.00	1.00	1.00	20
blackgram	1.00	0.95	0.97	20
chickpea	1.00	1.00	1.00	20
coconut	1.00	1.00	1.00	20
coffee	1.00	1.00	1.00	20
cotton	1.00	1.00	1.00	20
grapes	1.00	1.00	1.00	20
jute	0.95	1.00	0.98	20
kidneybeans	1.00	1.00	1.00	20
lentil	1.00	1.00	1.00	20
maize	0.95	1.00	0.98	20
mango	1.00	1.00	1.00	20
mothbeans	1.00	1.00	1.00	20
mungbean	1.00	1.00	1.00	20
muskmelon	1.00	1.00	1.00	20
orange	1.00	1.00	1.00	20
papaya	1.00	1.00	1.00	20
pigeonpeas	1.00	1.00	1.00	20
pomegranate	1.00	1.00	1.00	20
rice	1.00	0.95	0.97	20
watermelon	1.00	1.00	1.00	20
accuracy			1.00	440
macro avg	1.00	1.00	1.00	440
weighted avg	1.00	1.00	1.00	440

->KNN Relatório de Classificação:

	precision	recall	f1-score	support
apple	1.00	1.00	1.00	20
banana	1.00	1.00	1.00	20
blackgram	1.00	1.00	1.00	20
chickpea	1.00	1.00	1.00	20
coconut	0.95	1.00	0.98	20
coffee	1.00	1.00	1.00	20
cotton	0.95	1.00	0.98	20
grapes	1.00	1.00	1.00	20
jute	0.95	1.00	0.98	20
kidneybeans	0.95	1.00	0.98	20
lentil	0.91	1.00	0.95	20
maize	1.00	0.95	0.97	20
mango	0.95	1.00	0.98	20
mothbeans	0.94	0.85	0.89	20
mungbean	1.00	1.00	1.00	20
muskmelon	1.00	1.00	1.00	20
orange	1.00	0.90	0.95	20
papaya	1.00	1.00	1.00	20
pigeonpeas	1.00	0.90	0.95	20
pomegranate	0.95	1.00	0.98	20
rice	1.00	0.95	0.97	20
watermelon	1.00	1.00	1.00	20
accuracy			0.98	440
macro avg	0.98	0.98	0.98	440
weighted avg	0.98	0.98	0.98	440

FASE INICIAL: COMPARANDO OS MODELOS





FASE INICIAL: COMPARANDO OS MODELOS

->Tree Decision Relatório de Classificação:

	precision	recall	f1-score	support
apple	1.00	1.00	1.00	20
banana	1.00	1.00	1.00	20
blackgram	1.00	0.80	0.89	20
chickpea	1.00	1.00	1.00	20
coconut	1.00	1.00	1.00	20
coffee	1.00	1.00	1.00	20
cotton	1.00	1.00	1.00	20
grapes	1.00	1.00	1.00	20
jute	0.95	0.95	0.95	20
kidneybeans	1.00	1.00	1.00	20
lentil	0.86	0.90	0.88	20
maize	0.95	1.00	0.98	20
mango	1.00	1.00	1.00	20
mothbeans	0.86	0.95	0.90	20
mungbean	1.00	1.00	1.00	20
muskmelon	1.00	1.00	1.00	20
orange	1.00	1.00	1.00	20
papaya	1.00	1.00	1.00	20
pigeonpeas	1.00	1.00	1.00	20
pomegranate	1.00	1.00	1.00	20
rice	0.95	0.95	0.95	20
watermelon	1.00	1.00	1.00	20
accuracy			0.98	440
macro avg	0.98	0.98	0.98	440
weighted avg	0.98	0.98	0.98	440

->SVM Relatório de Classificação:

	precision	recall	f1-score	support
apple	1.00	1.00	1.00	20
banana	1.00	1.00	1.00	20
blackgram	0.95	1.00	0.98	20
chickpea	1.00	1.00	1.00	20
coconut	1.00	1.00	1.00	20
coffee	1.00	1.00	1.00	20
cotton	0.95	1.00	0.98	20
grapes	1.00	1.00	1.00	20
jute	0.80	1.00	0.89	20
kidneybeans	1.00	1.00	1.00	20
lentil	1.00	1.00	1.00	20
maize	1.00	0.95	0.97	20
mango	1.00	1.00	1.00	20
mothbeans	1.00	1.00	1.00	20
mungbean	1.00	1.00	1.00	20
muskmelon	1.00	1.00	1.00	20
orange	1.00	1.00	1.00	20
papaya	1.00	1.00	1.00	20
pigeonpeas	1.00	0.95	0.97	20
pomegranate	1.00	1.00	1.00	20
rice	1.00	0.75	0.86	20
watermelon	1.00	1.00	1.00	20
accuracy			0.98	440
macro avg	0.99	0.98	0.98	440
weighted avg	0.99	0.98	0.98	440

TÉCNICAS DE VALIDAÇÃO DOS MODELOS

Na fase inicial também foi utilizada uma técnica muito interessante para evitar o overfitting,

a validação cruzada:

LOOCV ➡ no nosso caso usa toda a base para treinar aumentando assim o desempenho, como possui na sua lógica poupar sempre uma classe para teste, podendo comprovar perfeitamente a capacidade de generalização entre os modelos testados apontando assim o ideal para a tarefa desejada.

TÉCNICAS DE VALIDAÇÃO DOS MODELOS LOOCV= VALIDAÇÃO CRUZADA(LEAVE-ONE-OUT)

```
Random Forest (Acurácia média com CV=5): 0.9945454545454545
Decision Tree (Acurácia média com CV=5): 0.9868181818181819
KNN (Acurácia média com CV=5): 0.9795454545454545
SVM (Acurácia média com CV=5): 0.9781818181818182
```

TÉCNICAS DE VALIDAÇÃO DOS MODELOS

Outra técnica utilizada nessa fase inicial foi a Variância Unidimensional(ANOVA/ONEWAY):

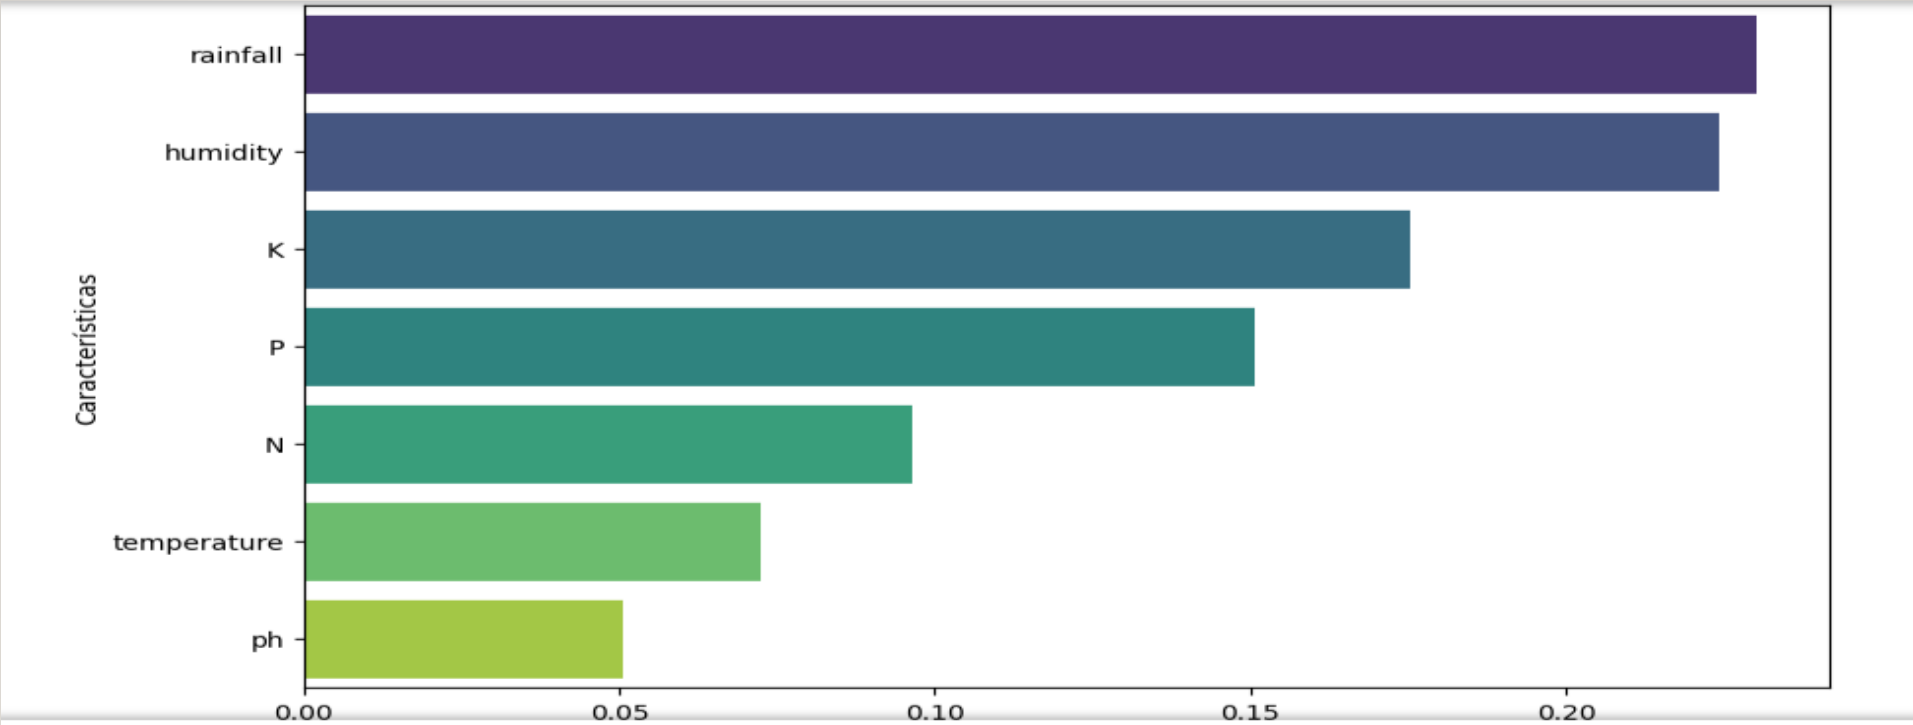
Essa técnica e relativa à medida estatística que quantifica os valores de uma única variável ou recurso(feature)se encontram dispersos em torno da média de 2,3 ou mais grupos.

Aponta a hipótese nula se existir e também a hipótese alternativa, caso ocorra.

TÉCNICAS DE VALIDAÇÃO DOS MODELOS

```
Estatística F: 22.448979591836856
p-variavel: 5.607041188574097 5e-06
```

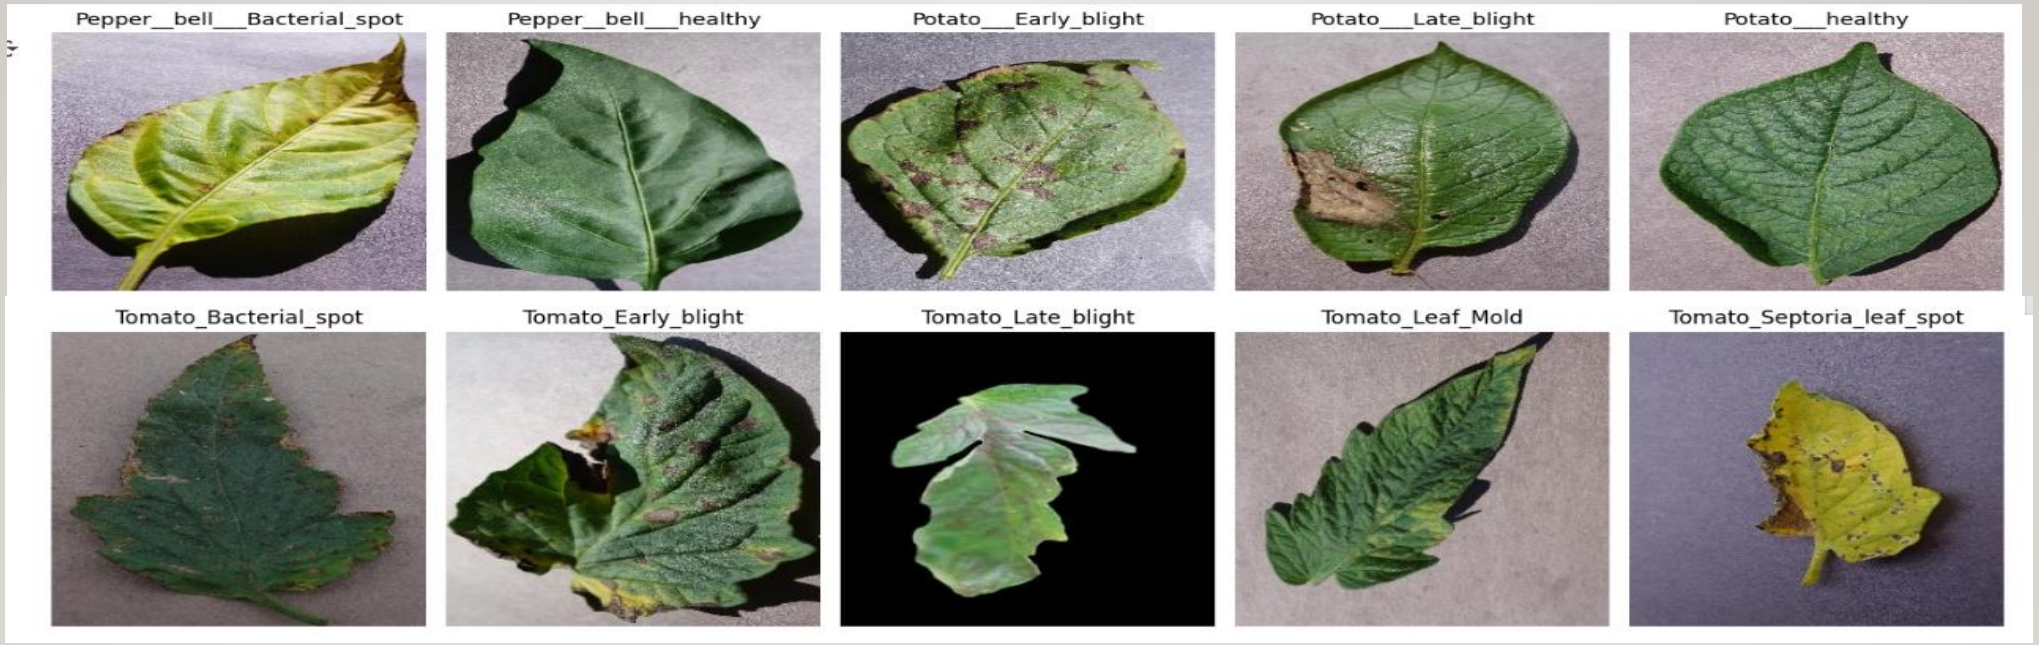
RECURSOS OBSERVADOS NA FASE INICIAL



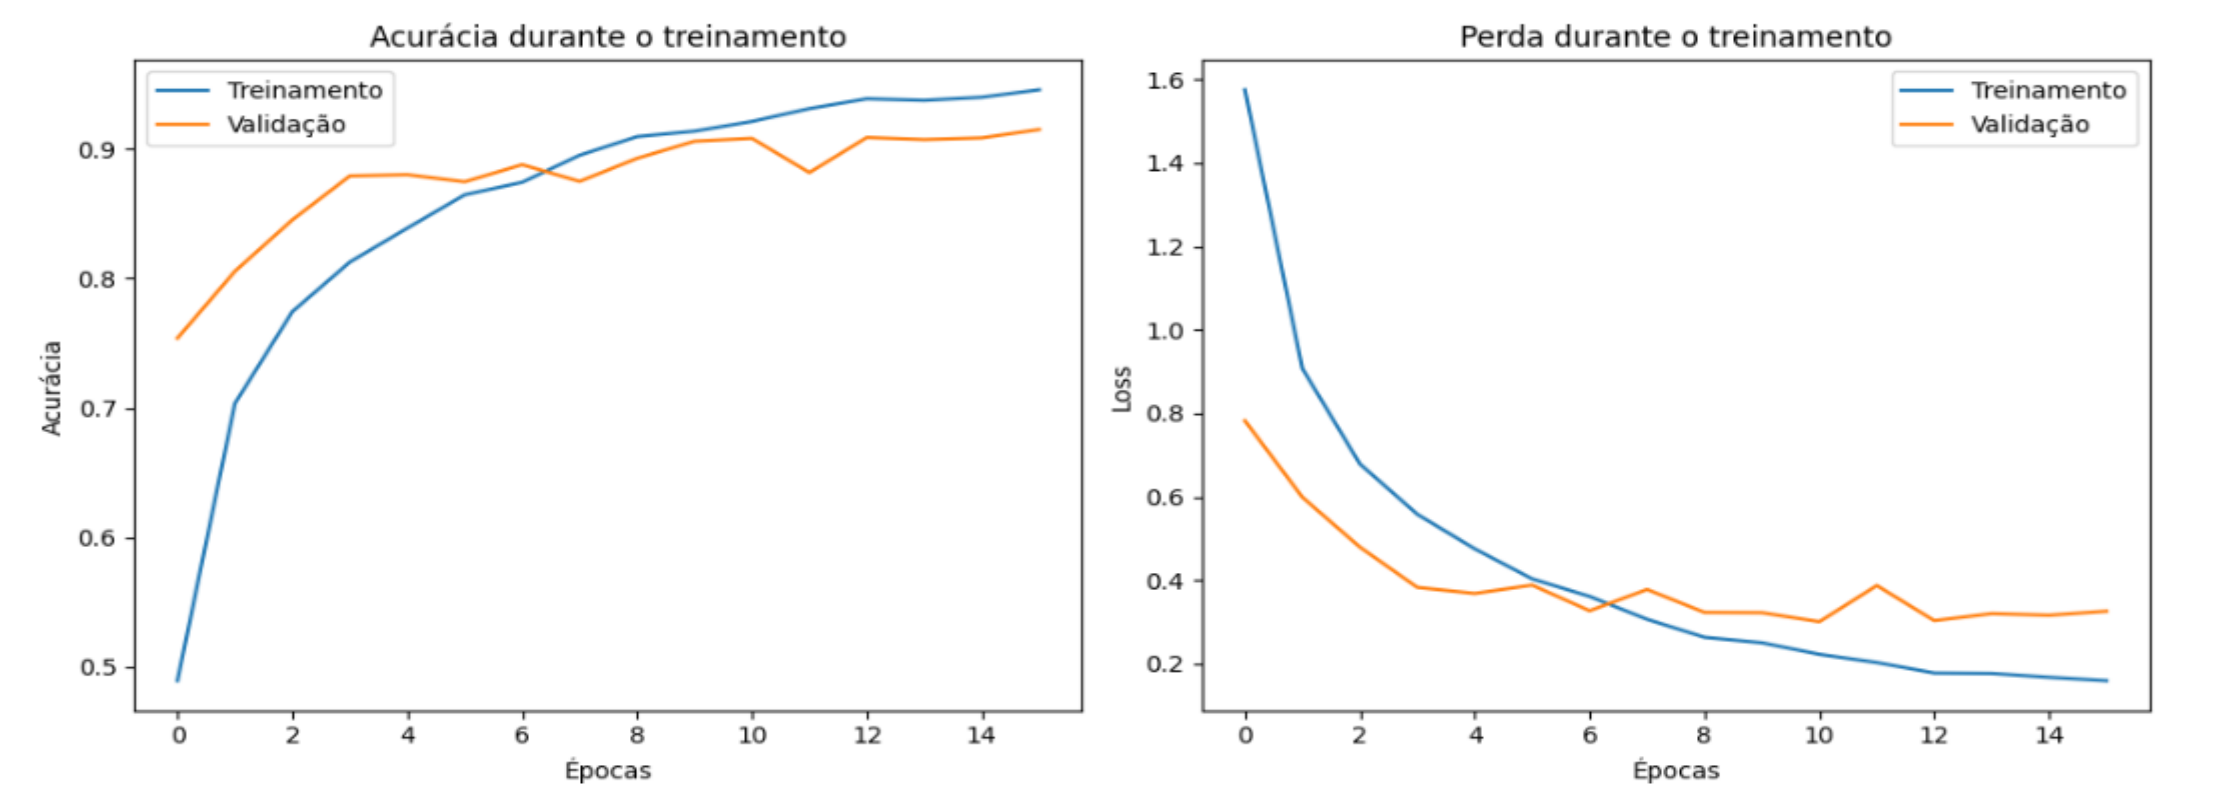
FASE II: MONITORAMENTO ATRAVÉS DE IMAGENS

Nessa fase do processo, a tarefa principal foi o monitoramento das plantas através de imagens, utilizamos o Dataset PlantVillage, um conjunto de dados robusto, possui uma grande diversidade de imagens contendo plantas sadias e também afetadas por doenças e pragas.
Foi implementada uma CNN(Convolutional Network Neural), muito utilizada e adequada para a extração de padrões através da aplicação de filtros e descartando características irrelevantes a cada convolução, aplicando a redução da dimensionalidade até alcançar a classificação densa, camada que contém os recursos necessários para a identificação da feature alvo. Também utilizamos o IMAGEDATAGENERATOR, que possibilitou ainda mais robustez na observação das imagens.

FASE II: MONITORAMENTO ATRAVÉS DE IMAGENS



FASE II:VALIDAÇÃO DO MODELO CNN



FASE III:CONTROLE DE RECURSOS E MANEJO COM BASE EM DADOS EXTRAÍDOS DE DISPOSITIVOS IOT

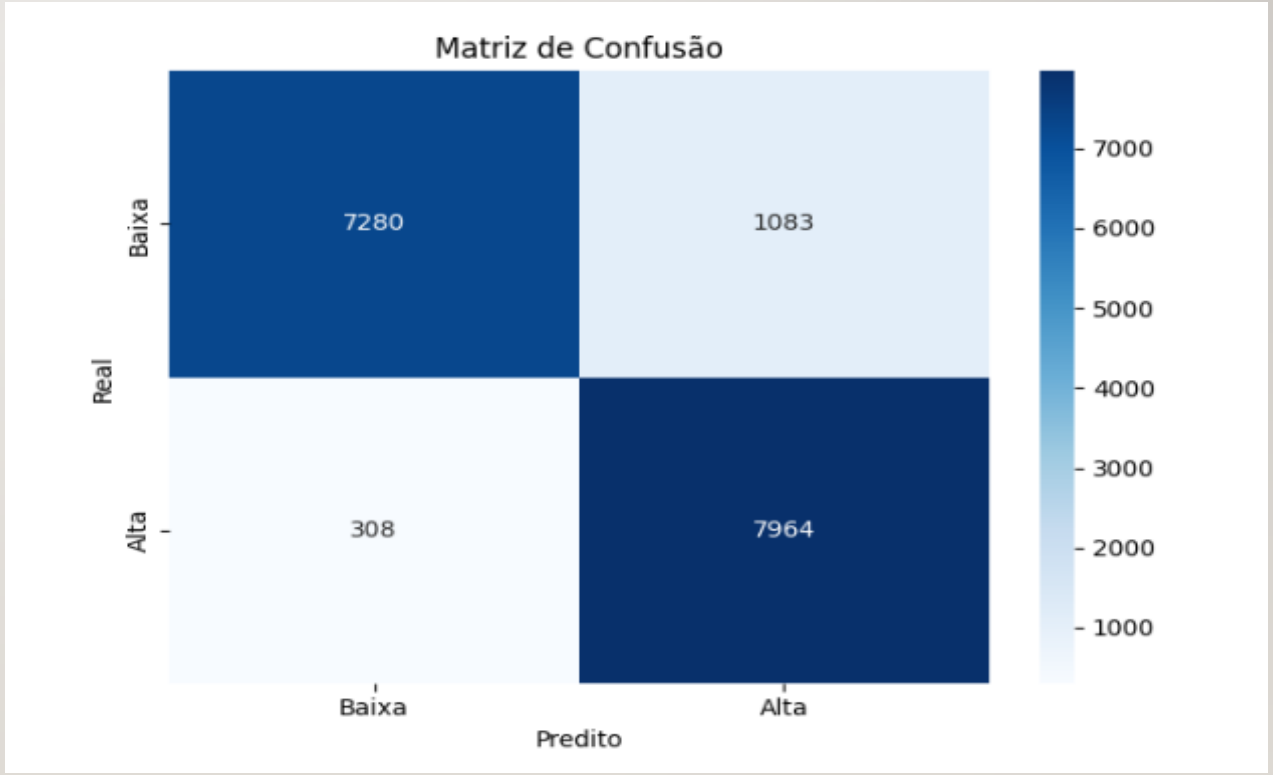
Um dos maiores desafios no Agronegócio atualmente é o controle de gastos e também o alto índice de perda na plantação. Baseados em dados oriundos de sensores, câmeras e até satélites podemos afirmar que é possível se não exterminar ao menos minimizar expressivamente as variáveis que contribuem para tais desperdícios.

Fazendo uso de um Dataset com dados de IOT foi possível implementar um modelo de machine learning: Tree Decision que não só observou os dados de solo, mas também de foliação, retenção de águas e peso biológico como também possibilitou responder perguntas relevantes como a correlação entre o peso biológico e quantidade de vagens, a retenção de águas e a produtividade da planta e até mesmo a coloração da espécie prevendo a qualidade da mesma .

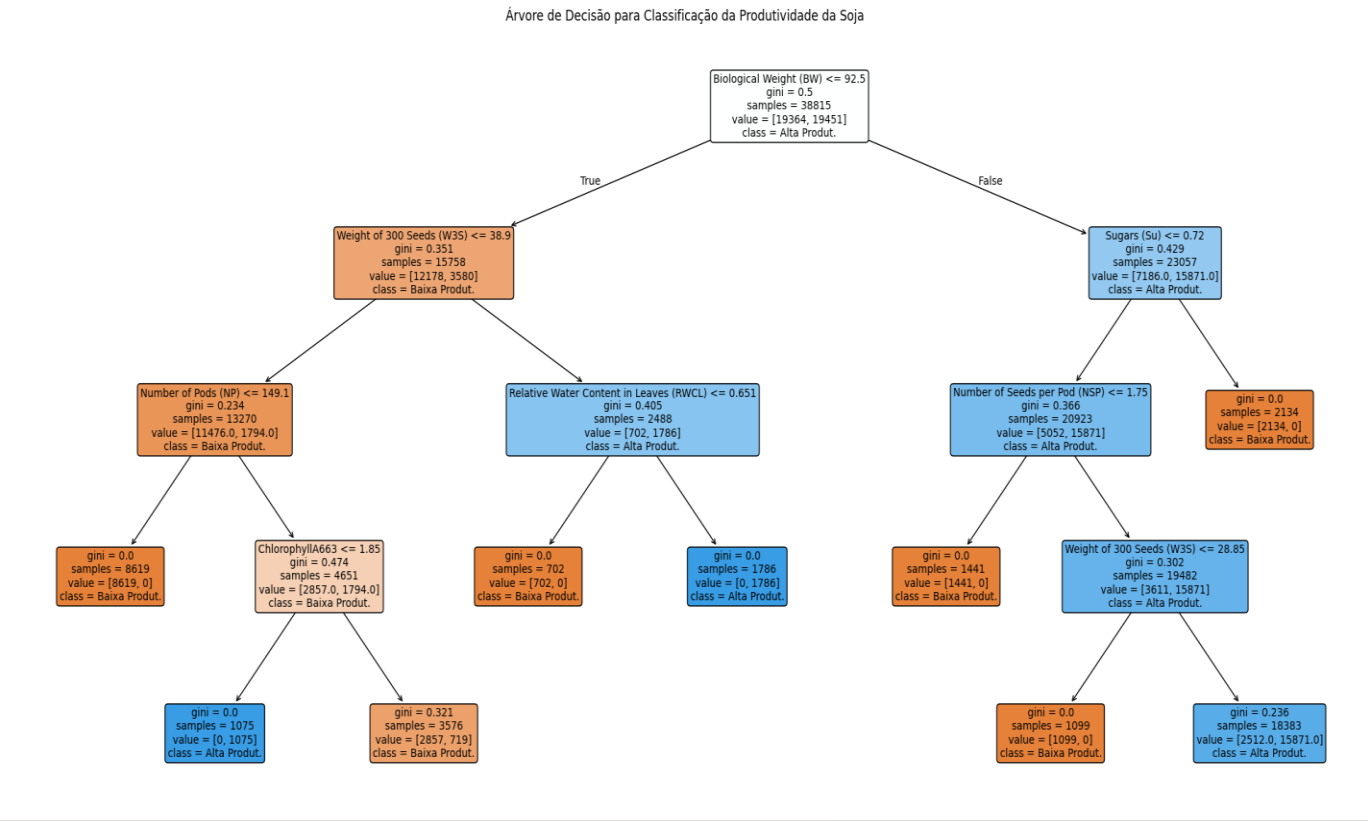
FASE III: IMPLEMENTAÇÃO DO ALGORITMO TREE DECISION E SUAS REGRAS

Classification Report:

	precision	recall	f1-score	support
0	0.96	0.87	0.91	8363
1	0.88	0.96	0.92	8272
accuracy			0.92	16635
macro avg	0.92	0.92	0.92	16635
weighted avg	0.92	0.92	0.92	16635



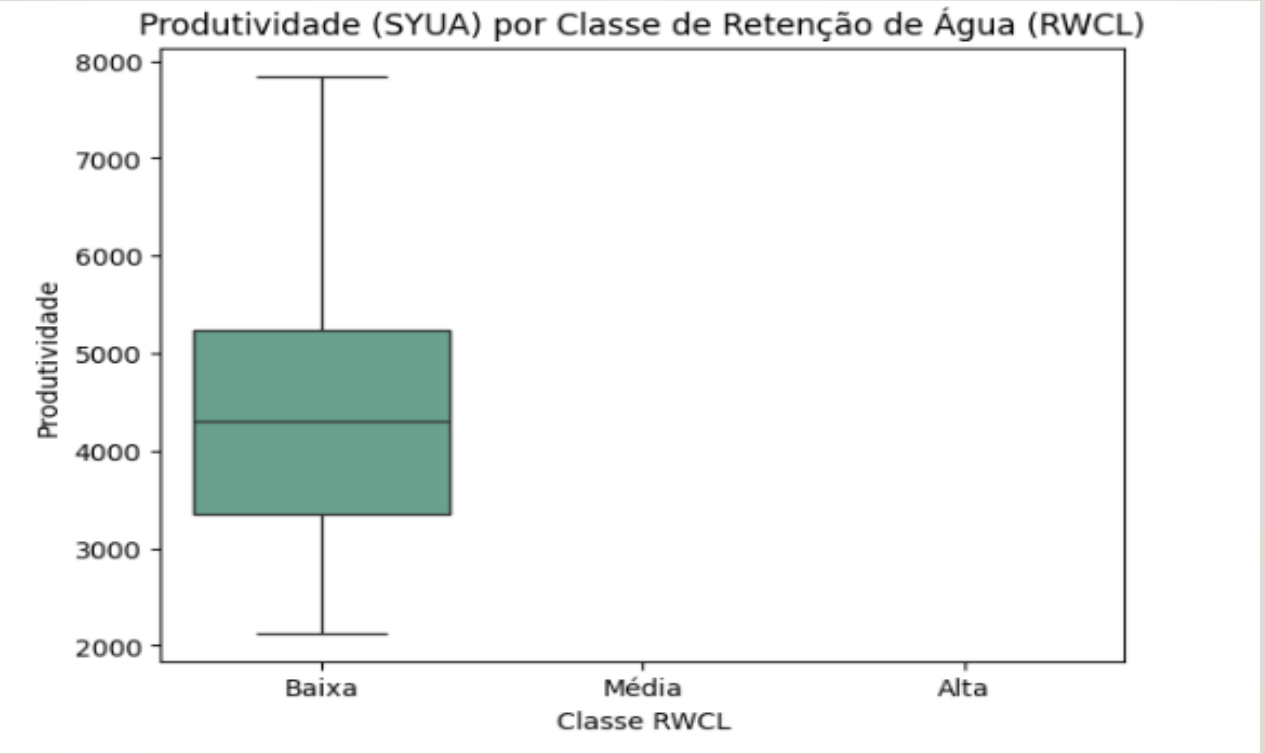
FASE III: PLOTAGEM DO MODELO TREE DECISION



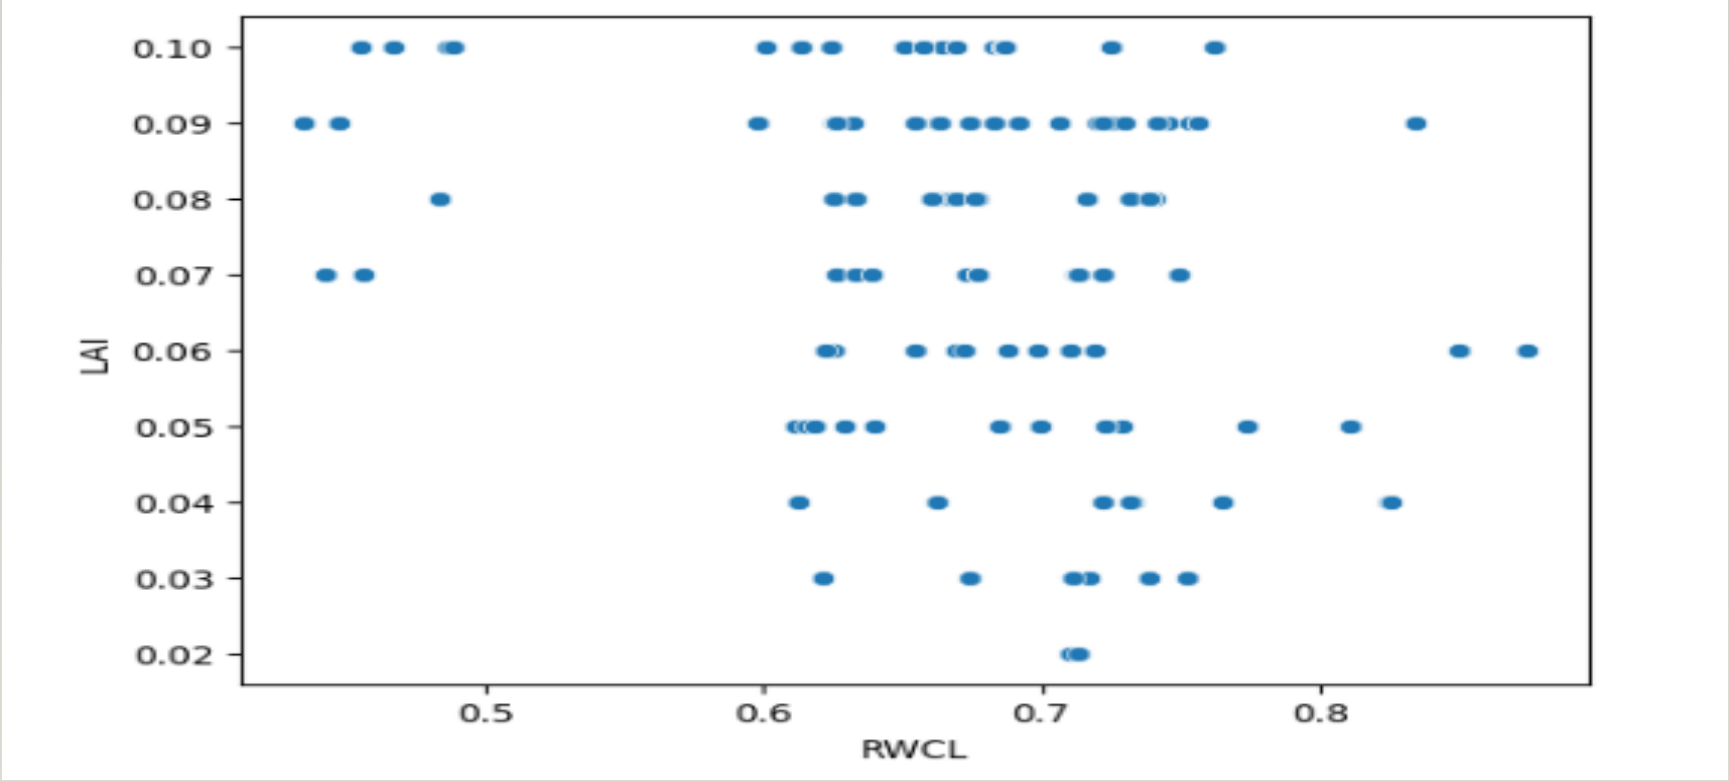

```
Regras da árvore:

|--- Biological Weight (BW) <= 92.50
|    |--- Weight of 300 Seeds (W3S) <= 38.90
|    |    |--- Number of Pods (NP) <= 149.10
|    |    |    |--- class: 0
|    |    |--- Number of Pods (NP) >  149.10
|    |    |    |--- ChlorophyllA663 <= 1.85
|    |    |    |    |--- class: 1
|    |    |    |--- ChlorophyllA663 >  1.85
|    |    |    |    |--- class: 0
|    |--- Weight of 300 Seeds (W3S) >  38.90
|    |    |--- Relative Water Content in Leaves (RWCL) <= 0.65
|    |    |    |--- class: 0
|    |    |--- Relative Water Content in Leaves (RWCL) >  0.65
|    |    |    |--- class: 1
|--- Biological Weight (BW) >  92.50
|    |--- Sugars (Su) <= 0.72
|    |    |--- Number of Seeds per Pod (NSP) <= 1.75
|    |    |    |--- class: 0
|    |    |--- Number of Seeds per Pod (NSP) >  1.75
|    |    |    |--- Weight of 300 Seeds (W3S) <= 28.85
|    |    |    |    |--- class: 0
|    |    |    |--- Weight of 300 Seeds (W3S) >  28.85
|    |    |    |    |--- class: 1
|    |--- Sugars (Su) >  0.72
|    |    |--- class: 0
```

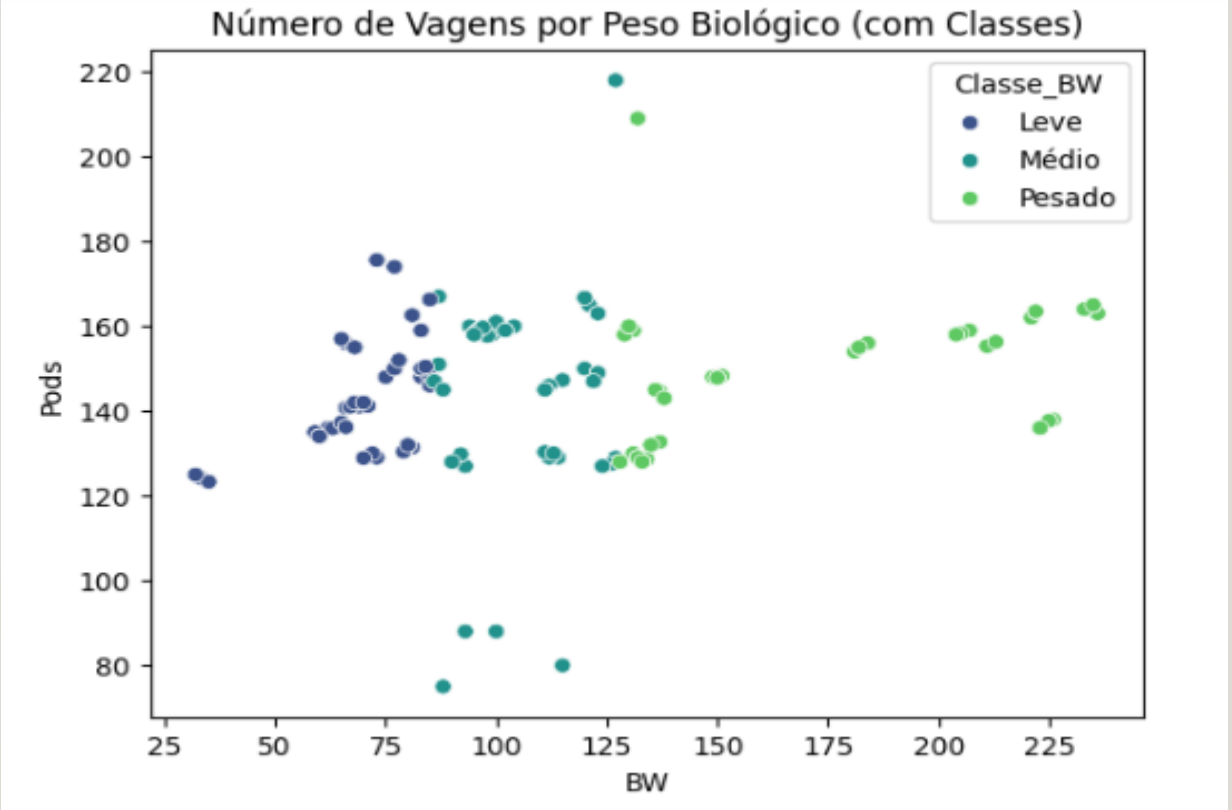
FASE III: PRODUTIVIDADE DA SOJA COM RELAÇÃO A CLASSE DE RETENÇÃO DE ÁGUA



FASE III: A PROPORÇÃO EM QUE A RETENÇÃO DE ÁGUA AUMENTA A FOLIAÇÃO TAMBÉM EVOLUI



FASE III: CORRELAÇÃO ENTRE O PESO BIOLÓGICO E O NÚMERO DE VAGENS



FASE IV: PREVISÃO ATRAVÉS DE DADOS DE SAFRAS PASSADAS PARA PLANEJAMENTO FUTUROS

Nessa última fase utilizamos o Dataset Agriculture CropYield contendo dados de safras anteriores e que serão referência para prevermos a próxima safra. Uma vez que os dados foram trabalhados e implementada a série temporal para o modelo de treinamento baseada na colheita por hectare das 3 safras anteriores pode-se prevêr a nossa próxima safra.